

AVP3:

Informe de Resultados y Conclusiones



por Santiago Pereira Olmeda,
Martín Rodríguez Penedo,
Lucas Andrea Martínez Calveiro.



Denominación	PLUTO
Cliente	CTAG
Fecha de inicio - Fecha de fin	19/02/2026 - 11/05/2026
Equipo	CTG_GT14_AVP3
Versión del documento	v1.0
Participante/s	Santiago Pereira Olmeda, Martín Rodríguez Penedo, Lucas A. Martínez Calveiro
Interlocutor/es	Andrés Salvador Paradela Estévez



Introducción y Propuesta de Valor del Proyecto

El proyecto PLUTO nace con el objetivo de explorar la viabilidad de la Inteligencia Artificial aplicada al control de calidad en entornos de industria avanzada.

Si bien el sistema desarrollado es un prototipo de naturaleza conceptual que no se desplegará directamente en las líneas de producción actuales del cliente, su propuesta de valor fundamental reside en la optimización del tiempo humano: **reducir y orientar el espacio de búsqueda del técnico de planta.**

En plantas industriales modernas donde cada pieza genera miles de variables, identificar la causa raíz de un defecto es una tarea imposible desde el punto de vista cognitivo y temporal. PLUTO actúa como un asistente inteligente que filtra el ruido, destaca los parámetro más críticos y ofrece un diagnóstico en lenguaje natural, arrojando luz sobre el problema y permitiendo al técnico enfocarse inmediatamente en los componentes con mayor probabilidad de fallo, operando bajo un paradigma estricto de privacidad de datos (*Local-First*).

Resultados Obtenidos y Objetivos no Alcanzados

Reevaluación de los KPIs Iniciales

En el AVP1, se establecieron inicialmente los siguientes KPIs objetivo:

KPI	Descripción	Meta
Precisión del clasificador	F1-score o PR-AUC sobre los datos de test	F1-score > 0.80 PR-AUC > 0.85
Cobertura de consultas	% de preguntas respondidas correctamente	> 75 %
Tiempo de respuesta	Latencia media por consulta del chatbot	< 45
Tasa de alucinación	% de información inventada por el LLM	< 5%



Durante la fase de experimentación se evidenció que la naturaleza del proyecto, tanto en el conjunto de datos como en el objetivo de la investigación, requería un cambio estratégico en la selección de métricas objetivo. El dataset proporcionado presenta un desbalanceo deliberado (mayoría de piezas defectuosas o NOK). Esta asimetría está diseñada para que el modelo aprenda de forma exhaustiva la topología del fallo, evitando falsos positivos y asegurando un reconocimiento estricto de las piezas conformes.

Por consiguiente, el equipo determinó que el **Recall de la clase OK** (la capacidad del modelo para no descartar erróneamente piezas buenas) era la métrica de negocio más crítica, priorizándola sobre métricas clásicas como PR-AUC. Como segunda métrica objetivo se mantuvo el F1-score global.


Resultados del Modelo de Clasificación

El modelo de clasificación final resultante de la fase de experimentación fue el del Experimento 05 (VAE + CatBoost). Este modelo alcanzó las siguientes métricas sobre el conjunto de test:

KPI	Descripción	Valor
F1-Weighted	Evalúa el rendimiento global del modelo ponderando los aciertos según el volumen de cada clase.	0.67
F1-Macro	Evalúa el rendimiento de forma estricta, dando exactamente la misma importancia a piezas OK y NOK.	0.57
Recall OK	<u>Porcentaje de piezas realmente correctas que el modelo logra identificar y salvar del falso rechazo.</u>	0.39
Recall NOK	Porcentaje total de piezas defectuosas que el sistema detecta y bloquea para evitar fallos críticos.	0.76



Comparativa con el resto de pipelines:



Aunque el F1 ni se acercó al 0.80 estipulado inicialmente, el F1-Macro de 0.57 refleja la extrema complejidad y el severo desbalanceo del conjunto de datos (90% NOK). De hecho, ningún modelo experimentado logró superar la barrera de 0.58 en esta métrica, lo que demuestra que el objetivo original era inalcanzable por la propia naturaleza de espacio latente de los datos.

Teniendo en cuenta este límite técnico, se seleccionó el Experimento 05 porque ofrece el mejor balance para el negocio: asume una pérdida controlada en la detección de piezas defectuosas a cambio de conseguir una altísima capacidad de rescatar aquellas piezas conformes.

En caso de ser necesario por temas de seguridad, esta tasa de falsos positivos puede regularse mediante un umbral de decisión estricto (Umbral de decisión actual = 0.4606). Esto garantiza la seguridad del modelo a costa de perder capacidad para detectar piezas correctas.



Resultados del Modelo de Lenguaje

KPI		Descripción	Meta	Resultado
Cobertura de Consultas	de	% de preguntas respondidas correctamente o gestionadas adecuadamente	> 75 %	~100 %
Tiempo de Respuesta	de	Latencia media por consulta del chatbot en hardware local.	< 45 s	28.24 s
Tasa de alucinación		% de información técnica inventada o tergiversada por el LLM.	< 5 %	~0 %

Análisis de Latencia

La latencia media de 28.24 segundos en 20 reproducciones cumple holgadamente el objetivo. En pruebas de estrés extremo (919 palabras), el sistema se mantuvo estable con una latencia de 66 segundos. Cabe destacar que estas pruebas se realizaron en hardware de consumo; el despliegue en la infraestructura de CTAG (GPU NVIDIA H100) reduciría la latencia a escasos segundos, garantizando una interacción en tiempo real.

Robustez frente a alucinaciones

El sistema erradicó prácticamente las alucinaciones. Fue sometido a escenarios adversos, como palabras y textos aleatorios fuera de dominio (“almendra”, 919 palabras del Quijote), preguntas ambiguas (“más o menos?”), y preguntas metatécnicas (“qué es SHAP?”). en todos los casos mantuvo su rol técnico sin inventar información.

Este éxito radica en la ingeniería del *System Prompt*: al preprocesar matemáticamente los valores SHAP e inyectarlos con una semántica explícita (ej. “ESTA VARIABLE EMPUJA A DEFECTO”), se bloqueó cualquier margen de malinterpretación, obligando al LLM a ceñirse exclusivamente a los datos validados por el explicador.



Objetivos finales no alcanzados

Chat interactivo para procesamiento por lotes: Durante el desarrollo de la interfaz, se implementó un sistema para dialogar con el LLM sobre un lote completo de piezas. Esta funcionalidad fue finalmente retirada. El motivo técnico fue que el sistema de inferencia por lotes solo proporcionaba la probabilidad final de defecto ($P(\text{NOK})$) para el conjunto, careciendo del contexto unificado de los valores SHAP individuales. Sin esta explicabilidad, el LLM perdía su capacidad de realizar diagnósticos, por lo que se optó por un enfoque más fiable: seleccionar piezas individualmente del lote y examinar su detalle exacto.

Problemas y Desviaciones sobre el Plan Inicial

El desarrollo del prototipo PLUTO experimentó una evolución técnica significativa respecto a los requisitos definidos en el documento AVP2, impulsada por la necesidad de alcanzar un rendimiento industrial real y resolver problemas de interpretabilidad surgidos durante la fase de experimentación.

Arquitecturas finales de Machine Learning: El plan original establecía el uso de la librería *scikit-learn* con algoritmos tradicionales (Random Forest, SVM, LightGBM) y técnicas de remuestreo como SMOTE para tratar el desbalanceo. Al comprobar que estos modelos no lograban aislar la clase minoritaria con eficacia, se movió el foco hacia una arquitectura híbrida: un Autoencoder Variacional (VAE) acoplado a CatBoost, lo que introdujo dimensiones latentes abstractas pero maximizó de forma decisiva el Recall OK.

Refactorización de Explicabilidad (SHAP): Inicialmente se preveía devolver las "top-k características más importantes" de forma directa. Sin embargo, la inclusión del VAE generó una pérdida de interpretabilidad que obligó a diseñar un módulo de explicabilidad avanzado basado en cinco pasos no planificados:

- Extracción nativa de SHAP desde CatBoost
- Suma de valores SHAP de variables derivadas a las originales
- Un filtro de relevancia del 15% frente a la variable principal
- Un balanceo dinámico para garantizar que los sensores físicos (reales) no quedaran ocultos por las variables del VAE
- Renombrado industrial automático.



Reestructuración frente al Data Leakage: El diseño conceptual proponía un pipeline de datos secuencial .

Normalización -> Balanceo -> Entrenamiento

En la práctica, este enfoque lineal provocó *data leakage*. Para solucionarlo, se tuvo que rediseñar la arquitectura de preprocesamiento, forzando a que los normalizadores y las imputaciones se ajustasen exclusivamente de forma aislada mediante validación cruzada estricta (*Out-Of-Fold*).

Ingeniería de Prompts ajustada para el LLM: El AVP2 contemplaba pasar al modelo de lenguaje el nombre de la variable y su peso numérico (ej. "Variable 37 (+0.35)") asumiendo una interpretación neutral. La experimentación demostró que Llama 3 malinterpretaba la semántica matemática de SHAP (asumiendo que un valor positivo indicaba "calidad"). Esto requirió abandonar la inyección directa y programar un *System Prompt* blindado que traduce explícitamente el impacto matemático a texto inamovible, erradicando así las alucinaciones técnicas.

Propuestas de Mejora y Evolución Futura

De cara a una hipotética continuación del proyecto junto a CTAG, se plantean las siguientes vías de evolución:

RAG para Lotes: Se propone vectorizar el lote completo junto con sus matrices SHAP en una base de datos documental temporal. Esto permitiría al LLM actuar como un agente RAG (*Retrieval-Augmented Generation*), donde el técnico podría preguntar, por ejemplo, "¿Cuáles son las piezas con mayor importancia en los resultados del lote de hoy?", "¿Cuál es la variable más importante en la tercera fila del lote?", y el sistema buscaría, agregaría y explicaría los datos sin necesidad de interacción manual.

Desanonimización del Espacio de Variables: Actualmente, el LLM razona sobre identificadores abstractos (ej. "Variable 97"). Si las políticas de confidencialidad de CTAG permitieran integrar los nombres reales, o nombres más explicables pero no oficiales de los sensores y la topología de la máquina, la capacidad de razonamiento causal del LLM se multiplicaría exponencialmente, permitiéndole inferir relaciones termodinámicas o mecánicas reales.



Implementación de una Red Bayesiana Híbrida: Utilizar las *Top-K* variables identificadas por SHAP para construir una red probabilística local. Esto permitiría al operario realizar análisis de simulaciones (¿qué pasaría si bajo la presión un 5%?) y entender las dependencias causales entre sensores que el modelo actual solo trata como correlaciones.

Conclusiones del Proyecto

El proyecto PLUTO demuestra que la combinación de un modelo de Redes Neuronales No Supervisadas y un modelo de Gradient Boosting es una solución altamente eficaz para la detección de anomalías en datasets de naturaleza industrial (fuertemente desbalanceados).

Desde la perspectiva operativa, el sistema cumple de manera sobresaliente el objetivo trazado por la mentoría de CTAG. Al traducir una predicción de "caja negra" compuesta por 113 dimensiones en una tabla filtrada de impacto neto y un diagnóstico en lenguaje natural de apenas unos párrafos, PLUTO demuestra que la IA en la industria no debe entenderse como un sustituto del ingeniero de calidad, sino como un reductor drástico de la carga cognitiva.

El proyecto sienta las bases algorítmicas y metodológicas para construir interfaces de asistencia humana que mitiguen el tiempo de inactividad de las máquinas guiando eficientemente el diagnóstico y el mantenimiento.